

Introdução aos modelos de previsão de séries temporais

VIII Encontro de Economia do Espírito Santo

Prof. Guilherme Pereira
Departamento de Economia - UFES

10 de novembro de 2021

1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- Amortecimento Exponencial de Holt
- Holt-Winters


Série temporal

- Variável aleatória observada ao longo do tempo.
 - dependência temporal!
- Escalas mais comuns em economia: diária, mensal, trimestral, anual etc.

Ex.


- Taxa de câmbio - R\$/US\$ - comercial compra média (diária)
- Preços de commodities - carnes - (mensal)
- PIB - (trimestral)
- Renda - desigualdade - coeficiente de Gini - (anual)
- Vendas / Receitas/ Custos de determinada empresa.
- Retornos diários das cotações (PETROBRAS, IBOVESPA...)

Exemplo I - Índice nacional de preços ao consumidor-amplio (IPCA)
Frequência: mensal - 01.2000 até 09.2021.



Exemplo II - Produção de cerveja na Austrália

Frequência: trimestral 01.1956 até 03.2008



Algumas características importantes

A análise de **séries temporais** busca identificar características importantes presentes nos dados tais como:

- tendência
- sazonalidade
- autocorrelação, dependência não-linear, etc.

Identificado tais padrões, estima-se o modelo mais adequado. Tal modelo pode ser utilizado para:


- previsão, simulação...

Identificando algumas características importantes...

- **tendência**
- estacionaridade
- sazonalidade
- autocorrelação, etc.

Ex: Tendência


Número total de vendas de passagens aéreas entre 1949 e 1960.



Identificando algumas características importantes...

- tendência
- **estacionaridade**
- sazonalidade
- autocorrelação, etc.


Ex: Série Estacionária




Identificando algumas características importantes...

- tendência
- estacionaridade
- sazonalidade
- autocorrelação, etc.

Ex: Sazonalidade



Seasonal plot: beer




Identificando algumas características importantes...

- tendência
- estacionaridade
- sazonalidade
- autocorrelação, etc.

Autocorrelação indica dependência linear de uma série temporal.

- dependência no tempo, isto é, o quanto Y_t depende das observações defasadas Y_{t-k} .
- $\rho(k) = \text{Corr}(y_t, y_{t-k}) = \frac{\text{Cov}[Y_t, Y_{t-k}]}{\sqrt{\text{Var}(Y_T), \text{Var}(Y_{t-k})}}$.
- $-1 < \rho(k) < 1$

Função de autocorrelação:



1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- Amortecimento Exponencial de Holt
- Holt-Winters

Decomposição clássica de séries temporais

Um série temporal (Y_t) pode ser decomposta em componentes:

- T_t : tendência-ciclo
- S_t : sazonalidade
- E_t : componente aleatório

Decomposição Aditiva

$$Y_t = T_t + S_t + E_t$$

Decomposição Multiplicativa

$$Y_t = T_t \times S_t \times E_t$$

Na *decomposição clássica* o objetivo é estimar cada um dos componentes.

Roteiro para decom. clássica

- 1 Estime \hat{T}_t (médias móveis, regressão...).
- 2 Remova a tendência da série ($Y_t - \hat{T}_t$ ou $\frac{Y_t}{\hat{T}_t}$).
- 3 Estime os fatores sazonais a partir da *série sem tendência* (médias do período, regressão com dummies...)
- 4 Estime o componente irregular ('resíduo')
 - $\hat{E}_t = Y_t - \hat{T}_t - \hat{S}_t$
 - $\hat{E}_t = Y_t / (\hat{T}_t \times \hat{S}_t)$
- 5 A nova série \hat{E}_t pode ser utilizada para análises, previsões e/ou estimação de modelos estacionários.

Exemplo de estimação dos componentes

\hat{T}_t - Média Móvel(m)

$$\hat{T}_t = \frac{1}{m} \sum_{j=-k}^k y_{t+j}, \quad m = 2k + 1.$$

\hat{S}_t - média do período


Em uma série mensal, por exemplo, \hat{S}_t pode ser a média(mediana) dos meses.

No R:


```
##### Decomposição Clássica #####  
  
# Carregando os dados do pacote fpp. Série do índice de novos pedidos  
# de fabricação de equipamentos eletrônicos.  
data(elecequip)  
  
decomp <- decompose(elecequip,type="additive")  
plot(decomp)  
  
# Podemos obter os componentes de forma isolada:  
# Componente sazonal  
decomp$seasonal  
# Componente de tendência  
decomp$trend  
# Componente "aleatório"  
decomp$random  
  
# Com base nos componentes e na série original, podemos obter, por exemplo,  
# a série "sem tendência"  
y_dessaz <- elecequip - decomp$trend  
plot(y_dessaz)
```

```
data(elecequip)  
decomp <- decompose(elecequip,type="additive")
```

Decomposition of additive time series



```
y_dessaz <- elecequip - decomp$trend  
plot(y_dessaz)
```



1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- Amortecimento Exponencial de Holt
- Holt-Winters

Previsão de séries temporais

Projeção de valores futuros a partir do passado.

- Utilizando a série histórica (y_1, y_2, \dots, y_T) realizamos previsões probabilísticas de $(\hat{y}_{T+1|T}, \hat{y}_{T+2|T}, \hat{y}_{T+h|T})$

Horizonte de previsão - Previsão h -passos à frente

- Número de instantes de tempo (passos à frente) a serem previstos.
 - Ex: Previsão 1 passo à frente de uma série mensal de vendas significa que irei prever o volume de vendas para o próximo mês.

Notação:

$\hat{y}_{T+1|T}$ é a previsão da variável y para o instante $T + 1$ tendo como origem o instante $t = T$.

Previsão de séries temporais

- previsão pontual
- previsão intervalar (intervalo de confiança)

Previsões podem ser de

- Curtíssimo prazo
- Curto prazo
- Médio prazo
- Longo prazo

A qualidade das previsões está sujeita

- principalmente ao grau de previsibilidade da série.
- ao horizonte de previsão.
 - incerteza aumenta conforme nos distanciamos do presente.

Erro de previsão

- Uma vez estimado determinado modelo, podemos utilizar este para projetar os valores históricos da série em análise.
- Podemos comparar os valores reais vs. valores previstos/valores ajustados.
- Ao calcularmos os valores reais **menos** os valores previstos, obtemos os **erros de previsão** um passo à frente.
- O erro de previsão será útil para estabelecermos métricas de avaliação dos modelos.

Erro de previsão


Erro de previsão

$$y_{t,real} - \hat{y}_{t,previsto} = \hat{\varepsilon}_t$$

$$y_t - \hat{y}_t = \hat{\varepsilon}_t$$

É desejável que os erros sejam os menores possíveis !

Na figura abaixo podemos observar os valores reais, previstos (dentro da amostra), os valores previstos fora da amostra (futuro) e os intervalos de previsão.



Métricas para avaliação

É importante termos em mente que as métricas de avaliação geralmente são calculadas com base no erro de previsão um passo à frente, i.e, $\hat{\varepsilon}_{t/t-1} = y_t - \hat{y}_{t/t-1}$.

Existem diversas métricas, contudo, neste minicurso iremos utilizar:

- MAPE
- RMSE

Métricas para avaliação

MAPE - mean absolute percentual erro

$$MAPE = \frac{\sum_{t=1}^T \frac{|\hat{\varepsilon}_{t/t-1}|}{y_t}}{T} \times 100$$

- Medida expressa o erro de previsão em termos percentuais.
- Pode ser utilizada para comparar modelos com escalas diferentes.
 - ex: y_t e $\log(y_t)$

RMSE - root mean square error

$$RMSE = \sqrt{\frac{\sum_{t=1}^T (\hat{\varepsilon}_{t/t-1})^2}{T}}$$

- Medida construída com base no erro quadrático.

1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- Amortecimento Exponencial de Holt
- Holt-Winters

A fase de diagnósticos de adequação é realizada sobre os resíduos estimados:

Resíduos estimados: $\hat{\varepsilon}_t = y_t - \hat{y}_t$ onde \hat{y}_t denota o valor previsto para o modelo.

Em um primeiro momento, analisamos as seguintes características dos resíduos:

- autocorrelação;
- normalidade;

Existem diversos testes disponíveis para cada uma dessas características, contudo, iremos apresentar os principais.

Normalidade - JB

Hipóteses:

- H_0 : Dados seguem uma distribuição normal.
- H_1 : Dados não seguem uma distribuição normal.

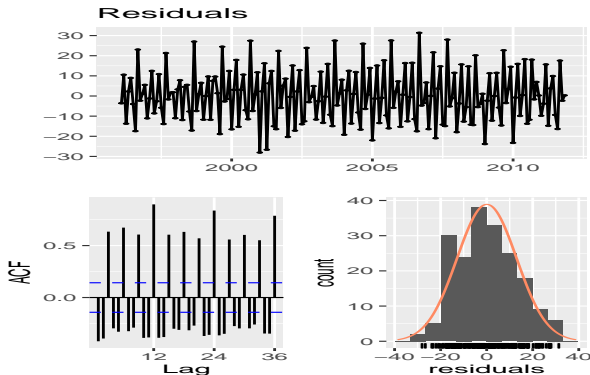
Autocorrelação: Teste de Ljung-Box

Hipóteses:

- H_0 : $\rho_1 = \rho_2 = \dots = \rho_k = 0$.
- H_1 : pelo menos um dos ρ s é diferente de zero.

Exemplo: análise dos resíduos obtidos a partir de um modelo Naive.

```
##### Análise dos resíduos #####  
data("elecequip") #lendo dados  
modelo.naive <- naive(elecequip) # estimando o modelo Naive  
residuo <- residuals(modelo.naive) # obtendo os resíduos do modelo  
  
# Análise Gráfica  
checkresiduals(residuo)
```



Saídas:

```
> # Teste de Ljung-Box
> Box.test(residuo, lag=10, type="Lj")

Box-Ljung test

data: residuo
X-squared = 413.57, df = 10, p-value < 2.2e-16

> #Normalidade
> tseries::jarque.bera.test(na.remove(residuo))

Jarque Bera Test

data: na.remove(residuo)
X-squared = 5.0908, df = 2, p-value = 0.07844
```

Conclusão:

- Os resíduos são autocorrelacionados.
- Os resíduos seguem uma distribuição normal.

Lembre-se que o desejado é que os resíduos não sejam autocorrelacionados e que sigam aproximadamente uma dist. normal.

1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- Amortecimento Exponencial de Holt
- Holt-Winters

Método ingênuo - naive

- Método bastante simples para previsão de séries temporais.
- A previsão para o instante t ($\hat{y}_{t+1|t}$) é dada pelo último valor observado (y_t).
- Modelos mais complexos devem ser comparados com este método.

Equação de previsão - método naive

- $\hat{y}_{t+1|t} = y_t,$
- $\hat{y}_{t+h|t} = y_t, \quad h = 1, 2, 3...$

1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- **Amortecimento Exponencial Simples**
- Amortecimento Exponencial de Holt
- Holt-Winters

Amortecimento Exponencial Simples (*Single Exponential Smoothing*)

- Indicado para séries livres tendência e sazonalidade.
- $\hat{y}_{T+1|T}$ é a previsão para y_{T+1} realizada em T .

O AES pondera todo o histórico da série para realizar a previsão:

$$\hat{y}_{T+1|T} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \dots \quad (1)$$

onde $\alpha \in (0, 1)$ é a constante de amortecimento.

- Todas as informações são amortecidas.

É possível demonstrar que a eq. 1 pode ser reescrita de forma sucinta:

$$\hat{y}_{t+1|t} = \alpha y_t + (1 - \alpha)\hat{y}_{t|t-1}$$

- Quanto maior o valor de α , maior será o peso dado a informação mais recente.
- Em séries mais "nervosas" geralmente utiliza-se um α maior.
- Em séries mais comportadas dá-se mais peso para informações passadas.
 - O modelo responde mais lentamente às mudanças no comportamento da série.

Ideia geral do modelo

$$\hat{y}_{t+1|t} = \alpha^* \text{presente} + (1 - \alpha)^* \text{passado}$$

Amortecimento Exponencial Simples no R

```
# Amortecimento Exponencial
data("oil")
oildata <- window(oil, start=1996)

#Estimando o modelo e realizando as previsões
modelo <- ses(oildata, h=3)
modelo$model

# Gráfico
autoplot(modelo,ylab="Oil production in Saudi Arabia",xlab="Year") +
  autolayer(fitted(modelo), series="Fitted")

#valores previstos
print(modelo)
```


Amortecimento Exponencial Simples no R

Forecasts from Simple exponential smoothing



```
> #valores previstos  
> print(modelo)
```

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
2011	469.2669	433.4186	505.1153	414.4416	524.0923	
2012	469.2669	423.6608	514.8730	399.5184	539.0155	
2013	469.2669	415.6505	522.8834	387.2676	551.2663	

1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- **Amortecimento Exponencial de Holt**
- Holt-Winters

Holt 2 parâmetros

- Similar ao AES porém possui o componente de tendência.
- Possui duas equações:
 - uma para o nível
 - uma para a tendência.

Modelo

$$\text{Equação de previsão: } \hat{y}_{t+h|t} = \ell_t + hb_t$$

$$\text{Equação do nível: } \ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$\text{Equação da tendência: } b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$$

onde ℓ_t , b_t denotam respectivamente o nível e a tendência prevista para o instante t , $0 < \alpha < 1$ é o parâmetro de suavização do nível e $0 < \beta < 1$ é o parâmetro de suavização da tendência.

Holt 2 parâmetro no R

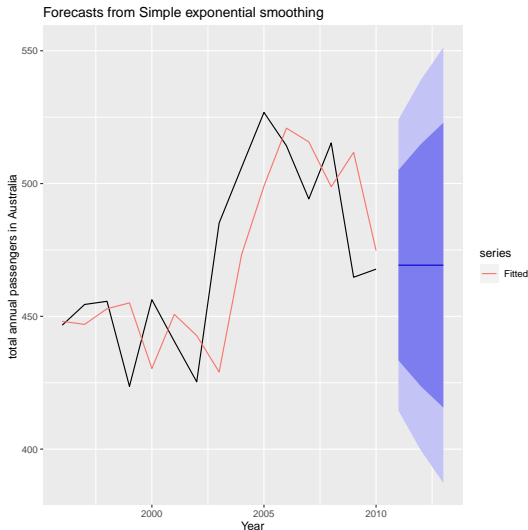
```
# Holt 2 Parâmetros
data("ausair")
air <- window(ausair, start=1990)
plot(air)

# Estimando o modelo & realizando as previsões.
modelo <- holt(air,h=5,level = c(80,90))
modelo$model

# Gráfico
autoplot(modelo,ylab="total annual passengers in Australia ",xlab="Year") +
  autolayer(fitted(modelo), series="Fitted")

#Valores previstos
print(modelo)
```

Holt 2 parâmetro no R



1 Conceitos gerais

- Decomposição clássica
- Previsão e métricas para avaliação
- Análise dos resíduos

2 Métodos de previsão

- Naive
- Amortecimento Exponencial Simples
- Amortecimento Exponencial de Holt
- Holt-Winters

Método de Holt-Winters

Método adequado para se modelar séries que possuem os seguintes componentes:

- nível (ℓ_t).
- tendência (b_t).
- sazonalidade (s_t)

A sazonalidade pode ser modelada da seguinte forma:

- aditiva
- multiplicativa

Modelo Aditivo

Equação de previsão:

- $\hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$

Equação do nível:

- $\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$

Equação da tendência:

- $b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$

Equação de suavização:

- $s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$

onde $\alpha, \beta, \gamma \in (0, 1)$ denotam os parâmetros de suavização para nível, tendência e sazonalidade respectivamente. k representa a parte inteira de $(h - 1)/m$

Modelo Multiplicativo

Equação de previsão:

- $\hat{y}_{t+h|t} = (\ell_t + hb_t)s_{t+h-m(k+1)}$

Equação do nível:

- $\ell_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(\ell_{t-1} + b_{t-1})$

Equação da tendência:

- $b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$

Equação de suavização:

- $s_t = \gamma \frac{y_t}{\ell_{t-1} - b_{t-1}} + (1 - \gamma)s_{t-m}$

Holt-Winters no R

```
#Holt-winters
data("austourists") # quarterly visitor nights in Australia spent by
#international tourists.
aust <- window(austourists,start=2005)


#Gráfico
plot(aust,ylab="Visitor Nights (millioins)",xlab="Year")
# Gráfico Sazonal
seasonplot(aust)

#Estimação e Previsão
modelo.ad <- hw(aust, h=12, seasonal = "additive",level = c(60,80, 95))
print(modelo.ad$model)
#modelo.mult <- hw(aust, h=12, seasonal = "multiplicative") - MULTIPLICATIVO

# Gráfico
autoplot(modelo.ad,ylab="Visitor Nights (millioins) ",xlab="Year") +
  autolayer(fitted(modelo.ad), series="Fitted")
```

Holt-Winters no R

Gráfico da série:



Holt-Winters no R

Componentes e constantes de amortecimento.

```
> print(modelo.ad$model)
Holt-winters' additive method

Call:
hw(y = aust, h = 12, seasonal = "additive", level = c(60, 80,
95))

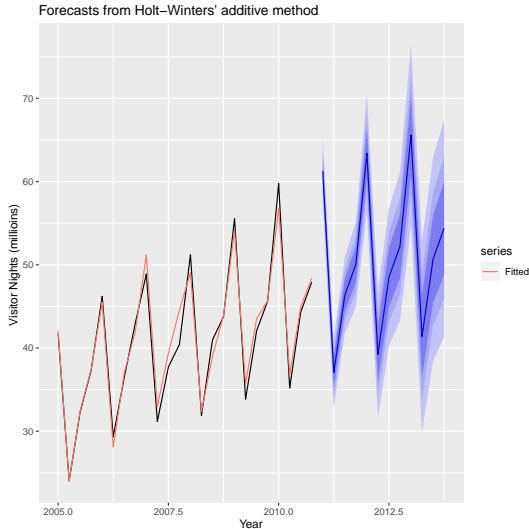
Smoothing parameters:
  alpha = 0.3625
  beta  = 0.0754
  gamma = 0.6375

Initial states:
  l = 31.6429
  b = 1.0028
  s = 2.0685 -2.0274 -9.4676 9.4264

sigma: 1.9369

      AIC      AICC      BIC
116.2736 129.1308 126.8761
```

Holt-Winters no R



Referências

- [1] Hyndman, R.J., & Athanasopoulos, G. (2018) Forecasting: principles and practice, 2nd edition, OTexts: Melbourne, Australia. [OTexts.com/fpp2](https://otexts.com/fpp2). Accessed on 08/11/2021.
- [2] Hyndman , R.J., (2013). fpp: Data for "Forecasting: principles and practice". R package version 0.5.
<https://CRAN.R-project.org/package=fpp>
- [3] Ferreira, P. C., de Mattos, D. M., de Almeida, D. C. V., & de Oliveira, I. C. L. (2017). Análise de Séries Temporais em R: curso introdutório. Elsevier.